

C. elegans RNA-seq11 Adapter 最新进展

从可工作的 128bp 基线到面向生物信号的 1bp residual 模型

Ziyang Huang

2026-06-04

上次的结论是：128bp adapter 已经可用，但还只是起点

- Frozen AlphaGenome trunk + 128bp RNA-seq adapter 已经能工作。
- 数据是 11 个 grouped *C. elegans* RNA-seq tracks。
- 染色体划分保持不变：train 为 I-IV，valid 为 V，test 为 X。
- 上次选中的模型：valid MSE 1.06099，Pearson 0.58810。
- 当时 1bp adapter 和 LoRA pilots 都还没有超过 128bp adapter。

本次汇报承接上次 128bp baseline；后续模型选择仍只基于 validation split。

旧 128bp 基线并没有饱和

模型	Valid MSE	Pearson	主要变化
Old 128bp baseline	1.06099	0.58810	第一个可工作的 adapter
Improved 128bp model	0.88033	0.67392	更好的 head、loss 和 schedule


Loss 做法: Improved 128bp model 在 full-log1p target 上训练 hybrid loss, 即 $\alpha \cdot \text{MSE} + (1 - \alpha) \cdot \text{SmoothL1}$; validation 指标仍用 unweighted full MSE/Pearson。

结论

在改变 representation strategy 之前, 只通过更合适的 objective 和 schedule, valid MSE 已经从 1.06099 明显降到 0.88033。

1bp 信息在 residual correction 里变得有用

模型	Valid MSE	Pearson
Improved 128bp model	0.88033	0.67392
1bp residual model	0.83558	0.69463



- 早期 naive 1bp pilots 没有赢。
- 但在强 128bp base 上叠加 1bp residual correction, validation performance 明确提升。
- 因此 1bp 更适合作为 correction layer, 而不是直接替代 128bp。

Residual correction 是在 frozen 128bp prediction 上加一个小修正

实际做法

- 先用 improved 128bp model 产生 full-resolution base prediction。
- 这个 128bp base head 和 AlphaGenome trunk 都保持 frozen。
- 另加一个 trainable 1bp residual head, 只预测 correction update。
- 最终输出不是替换 base, 而是 base + scaled 1bp update。

模型形式

$$\hat{y} = \text{stopgrad}(\hat{y}_{128}) + s_{\text{track}} \cdot \Delta_{1bp}$$

Term	Meaning
$\hat{y}_{128}$	frozen 128bp base prediction
Δ_{1bp}	1bp head predicted residual
s_{track}	trainable per-track scale

直观上: 128bp base 保留稳健的 broad RNA-seq prediction; 1bp head 只负责补局部、高频或 high-signal 误差。

最好的模型已经进入一个很窄的 plateau

Top15 的共同模式

- Top15 模型全部是同一策略的变体：frozen 128bp prediction + 1bp residual correction。
- Top15 full-MSE spread 只有约 0.00137。
- 模型差异主要来自 warm-start、learning rate、beta 和 track weights。
- Track-weighted loss 做法：训练时给指定 tracks 的每个有效位置乘更高权重；validation full metrics 仍保持 unweighted。

解释

继续做同方向的小型 continuation run 不太可能解决剩下的生物学错误；问题已经从“能不能预测 RNA-seq”转向“哪些重要信号还没学好”。

当前最佳模型仍然漏掉关键生物信号

失败模式	Metric
High > 3 signal MSE	4.9257
Top 5% true signal MSE	5.8610
Top 1% true signal MSE	10.8414
Exon MSE	1.6658
Gene-body MSE	1.1104
Gene-level Spearman	0.5835
Local-gradient Pearson	0.3451

结论

Global MSE 已经改善，但 high-expression amplitude、exon/gene-body regions、intestine tracks 和 local boundaries 仍然偏弱。

Signal-weighted loss 能改善 amplitude, 但有代价

模型	Full MSE	high_gt3 MSE	top5 MSE	top1 MSE
1bp residual reference	0.8356	4.9257	5.8610	10.8414
Signal top5x3	0.8632	4.1605	4.9061	9.2685
Signal intestine-high	0.8531	4.3510	5.1905	9.8277

Loss 做法: 在训练 batch 内按 true signal 选 high > 3、top5%、top1% 或 intestine T1/T3/T4 high-signal 元素, 把这些元素的基础 loss 乘上 preset factor, 例如 top5x3 表示 top5 true-signal 元素权重为 3 $\times$ 。

结论

Signal weighting 可以恢复 high-expression amplitude, 但会牺牲 global MSE。它应被视为 high-signal / intestine co-winner, 而不是 all-purpose model。

Region-weighted loss 能改善 exon 和 gene-body 信号

模型	Full MSE	Exon MSE	Gene-body MSE	Intergenic MSE
Reference	0.8356	1.6658	1.1104	0.2980
Region exon-gene v2	0.8367	1.6591	1.1083	0.3048
Region exon-gene v1	0.8377	1.6550	1.1079	0.3084

Loss 做法：用 WBCel235 GTF 在每个训练窗口生成 exon、gene-body、promoter、intron、intergenic 位置权重，再把 per-base 基础 loss 乘上这些权重；v1 权重更强，v2 更温和。

结论

Region weighting 直接降低 exon/gene-body error。v2 是更平衡的 biological-utility candidate；v1 是最强的 exon/gene-body candidate。

Gene auxiliary loss 和 calibration 还不是主方向

- Gene auxiliary loss 做法：在主 per-base loss 外，加 $\lambda \cdot \text{MSE}(\text{predicted gene-body mean}, \text{true gene-body mean})$ ，只统计 gene-body overlap 足够长的基因。
- Gene auxiliary loss $\lambda = 0.03$ 在测试设置下没有改善 gene-body mean MSE。
- 因为低 lambda 没有出现正向 gene-MSE signal，更大的 lambda 值没有被优先推进。
- Calibration 做法：冻结已有 prediction head 后只训练 per-track affine output scale/shift；它是输出校准，不是新的 weighted loss。
- Track-affine output calibration 只带来小幅 amplitude 改善，没有形成明确的新 winner。

结论

Gene auxiliary loss 和 calibration 是有用的工具，但不是当前最主要的推进方向。

171 个 checkpoint 被重新做了 validation-only 诊断

重新评估的内容

- full MSE / Pearson, 作为 sanity reference
- gene-level Pearson / Spearman
- high-signal top1 / top5 amplitude
- exon / gene-body / intergenic regions
- intestine T1/T3/T4
- 128bp 和 1kb pooled metrics
- downstream gene-profile probe

目的

所有评估都保持 validation-only; 目标是判断哪个模型更能保留有用的 biological signal, 而不只是哪个模型 pixel-level MSE 最低。

完整 run path 已记录在 docs; 正文不堆长 run directory。

最终解释应该是一组 purpose-specific winners

角色	模型	原因
MSE 参考	1bp residual rank1	full MSE 最低, 0.83558
主要生物 utility 候选	Region exon-gene v2	utility 最平衡, MSE 代价很小
exon/gene-body winner	Region exon-gene v1	exon/gene-body metrics 最好
high-signal winner	Signal top5x3	high-expression amplitude 最强
intestine high-signal winner	Intestine-high weighted	intestine high-signal behavior 最好

结论

MSE winner 仍然重要, 但它不是唯一具有 biological utility 的模型。

Take-home message: 下一步应按用途选模型

- 我们从上次 128bp baseline 的 MSE 1.06099, 提高到更强 128bp 训练和 1bp residual correction 的 0.83558。
- Diagnostics 显示剩余瓶颈是 biologically important signal: high expression、exon/gene-body regions 和 intestine tracks。
- Region-weighted 与 signal-weighted objectives 找到了可用于 downstream biological interpretation 的 co-winners。

下一步

保留 1bp residual MSE winner 作为 reference; 使用 region-weighted model 作为 main biological-utility candidate; 在 high-expression / intestine-focused analyses 中使用 signal-weighted models。