

C. elegans 11-track RNA-seq AlphaGenome Adapter Experiments

Frozen trunk adaptation, baselines, and follow-up pilots

Ziyang Huang

2026-05-18

数据与划分


- Reference: *C. elegans* WBcel235
- 20 个 sample-level RNA-seq bigWig
- 整理为 11 个 grouped RNA-seq tracks
- window: 1,048,576 bp
- stride: 524,288 bp
- target: clip negative + log1p

Split	Chromosome	NPZ
Train	I–IV	116
Valid	V	39
Test	X	33

MtDNA excluded; chromosome holdout.

Tensor	Shape
DNA input	$[B, 4, 1048576]$
RNA-seq target	$[B, 11, 1048576]$
mask	$[B, 11, 1]$

模型结构



Head output is on the 128 bp grid, then linearly interpolated to 1,048,576 target positions.


Trainable

adapter head: **33,803** parameters

Frozen


AlphaGenome trunk: **450,452,613** parameters

主结果: valid MSE



模型选择只看 valid。test 只在最终 selected checkpoint 上评估一次。

128 bp adapter 训练曲线




valid/test 总体指标

Split	MSE	MAE	Pearson
Valid	1.0609935	0.71866247	0.58809888
Test	1.1711332	0.76486897	0.55539986

解释


Test 与 valid 指标接近，跨染色体泛化表现稳定。

per-track Pearson



Muscle tracks generally show higher Pearson than intestine tracks in this split.

1 bp 与 LoRA: 可行但未提升



1 bp

更细，但更慢、更吃显存；当前预算下不如 128 bp。

LoRA

Phase A: 加载 5000-step best head, 冻结 head, 只训练 last-block LoRA。

Phase B: 同样加载 best head, LoRA 和 head 一起训练。

实验设计判断

- 先做 frozen adapter 是合理的：小数据下避免过度扰动 450M trunk。
- baseline 是必要的：证明结果不是 train mean 或 tiny Conv 就能达到。
- 128 bp 是当前最佳工作点：效果强、显存低、训练稳定。
- 1 bp 和 LoRA 仍有价值，但应作为下一轮 validation-only tuning。
- test 已使用一次；后续不应用 test 继续选模型。

与原 AlphaGenome 训练的差异

维度	当前实验
目标	11 个 grouped C. elegans RNA-seq tracks
数据规模	116 train windows, chromosome holdout
训练范围	冻结 trunk, 只训练 33,803 参数 adapter head
分辨率	selected model 使用 128 bp embedding
loss	log1p RNA-seq 上的 dense masked MSE
结论边界	下游适配, 不是原论文 benchmark 复现

核心结论

- 当前最佳：冻结 AlphaGenome trunk + 128 bp RNA-seq adapter
- valid: MSE **1.0609935**, Pearson **0.5881**
- test: MSE **1.1711332**, Pearson **0.5554**
- 1 bp adapter 和 last-block LoRA 暂未超过 128 bp adapter

这是基于预训练 AlphaGenome-style 权重的 C. elegans RNA-seq 下游适配实验，不是原论文训练复现。